The background of the slide features a close-up of a man's face, partially obscured by a large, semi-transparent teal triangle on the left. Overlaid on the image are various digital and network graphics, including glowing blue lines, hexagons, and data points. In the upper right, there are some numerical values like '51.07' and '51.04' within blue rectangular boxes. The overall aesthetic is high-tech and data-oriented.

Analytics e Inteligência Artificial Data Science

Tema da aula
Séries Temporais



BUSINESS SCHOOL

Graduação, pós-graduação,
MBA, Pós- MBA, Mestrado
Profissional, Curso In
Company e EAD



CONSULTING

Consultoria personalizada
que oferece soluções
baseadas em seu
problema de negócio



RESEARCH

Atualização dos
conhecimentos e do material
didático oferecidos nas
atividades de ensino



Líder em Educação Executiva, referência de ensino nos cursos de graduação, pós-graduação e MBA, tendo excelência nos programas de educação. Uma das principais **escolas de negócio do mundo**, possuindo convênios internacionais com Universidades nos EUA, Europa e Ásia. +8.000 **projetos de consultorias** em organizações públicas e privadas.



Único curso de graduação em administração a receber as notas máximas



A primeira escola brasileira a ser finalista da maior competição de MBA do mundo



Única *Business School* brasileira a figurar no *ranking* LATAM



Signatária do Pacto Global da ONU



Membro fundador da ANAMBA - Associação Nacional MBAs



Credenciada pela AMBA - Association of MBAs



Credenciada ao Executive MBA Council



Filiada a AACSB - Association to Advance Collegiate Schools of Business



Filiada a EFMD - European Foundation for Management Development



Referência em cursos de MBA nas principais mídias de circulação



O **Laboratório de Análise de Dados** – LABDATA é um Centro de Excelência que atua nas áreas de ensino, pesquisa e consultoria em análise de informação utilizando técnicas de **Big Data, Analytics** e **Inteligência Artificial**.



Profª Drª Alessandra Montini

O LABDATA é um dos pioneiros no lançamento dos cursos de *Big Data* e *Analytics* no Brasil. Os diretores foram professores de grandes especialistas do mercado.

- +10 anos de atuação.
- +9.000 alunos formados.

Docentes

- Sólida formação acadêmica: doutores e mestres em sua maioria;
- Larga experiência de mercado na resolução de *cases*;
- Participação em congressos nacionais e internacionais;
- Professor assistente que acompanha o aluno durante todo o curso.

Estrutura

- 100% das aulas realizadas em laboratórios;
- Computadores para uso individual durante as aulas;
- 5 laboratórios de alta qualidade (investimento +R\$2MM);
- 2 unidades próximas à estação de metrô (com estacionamento).



PROFA. DRA. ALESSANDRA DE ÁVILA MONTINI

Diretora do LABDATA-FIA, apaixonada por dados e pela arte de lecionar. Tem muito orgulho de ter criado na FIA cinco laboratórios para as aulas de Big Data e Inteligência Artificial. Possui mais de 20 anos de trajetória nas áreas de Data Mining, Big Data, Inteligência Artificial e Analytics. Cientista de dados com carreira realizada na Universidade de São Paulo. Graduada e mestra em Estatística Aplicada pelo IME-USP e doutora pela FEA-USP. Com muita dedicação chegou ao cargo de professora e pesquisadora na FEA-USP, ganhou mais de 30 prêmios de excelência acadêmica pela FEA-USP e mais de 30 prêmios de excelência acadêmica como professora dos cursos de MBA da FIA. Orienta alunos de mestrado e de doutorado na FEA-USP. Parecerista da FAPESP e colunista de grandes portais de tecnologia.





PROF. ÂNGELO CHIODE, MSc

Bacharel, mestre e candidato ao PhD em Estatística (IME-USP), atua como professor de Estatística Aplicada para turmas de especialização, pós-graduação e MBA na FIA. Trabalha como consultor nas áreas de Analytics e Ciência de Dados há 13 anos, apoiando empresas na resolução de desafios de negócio nos contextos de finanças, aquisição, seguros, varejo, tecnologia, aviação, telecomunicações, entretenimento e saúde. Nos últimos 5 anos, tem atuado na gestão corporativa de times de Analytics, conduzindo projetos que envolviam análise estatística, modelagem preditiva e *machine learning*. É especializado em técnicas de visualização de dados e design da informação (Harvard) e foi indicado ao prêmio de Profissional do Ano na categoria Business Intelligence, em 2019, pela Associação Brasileira de Agentes Digitais (ABRADi).



Conteúdo Programático

6



DISCIPLINAS




**IA E TRANSFORMAÇÃO
DIGITAL**



ANALYTICS



**INTELIGÊNCIA ARTIFICIAL:
MACHINE LEARNING**



**INTELIGÊNCIA ARTIFICIAL:
DEEP LEARNING**



**EMPREENDEDORISMO E
INOVAÇÃO**



**COMPORTAMENTO
HUMANO E SOFT SKILLS**

TEMAS: ANALYTICS E MACHINE LEARNING

ANÁLISE EXPLORATÓRIA DE DADOS

INFERÊNCIA ESTATÍSTICA

TÉCNICAS DE PROJEÇÃO

TÉCNICAS DE CLASSIFICAÇÃO

TÓPICOS DE MODELAGEM

TÉCNICAS DE SEGMENTAÇÃO

TÓPICOS DE ANALYTICS

MANIPULAÇÃO DE BASE DE DADOS

AUTO ML

TEMAS: DEEP LEARNING

REDES DENSAS

REDES CONVOLUCIONAIS

REDES RECORRENTES

MODELOS GENERATIVOS

FERRAMENTAS

LINGUAGEM R

LINGUAGEM PYTHON

DATABRICKS



Conteúdo da Aula

- 1. Introdução
- 2. Objetivo
- 3. Componentes da Série
 - Tendência e Sazonalidade
 - Estacionariedade
 - Teste Generalizado de Dickey-Fuller (DF-GLS)
- 4. Modelos para Séries Estacionárias
 - AR
 - MA
 - ARMA
- 5. Modelos para Séries Não Estacionárias
 - ARIMA
 - SARIMA
- 6. Modelo com Variáveis Exógenas
 - Regressão Linear Temporal
- Referências Bibliográficas



1. Introdução



Case: Vendas

1. INTRODUÇÃO | SÉRIES TEMPORAIS

Exemplo:

Prever a quantidade de vendas de um determinado produto no próximo mês, com base no histórico mensal de vendas, a fim de dimensionar o estoque necessário e ajustar estratégias de precificação.

Aplicação:

Área comercial



Case: Tráfego Virtual

1. INTRODUÇÃO | SÉRIES TEMPORAIS

10

Exemplo:

Predizer a quantidade de acessos que um site de *e-commerce* receberá nas próximas semanas, a fim de otimizar a capacidade dos servidores, planejar recursos e garantir a boa experiência do usuário, caso haja alta demanda.

Aplicação:

Área de tecnologia



Case: Consumo de Água

1. INTRODUÇÃO | SÉRIES TEMPORAIS

11

Exemplo:

Prever o consumo de água potável de um determinado bairro ou região nos próximos meses, para realizar um bom planejamento do processo de tratamento e distribuição do volume de água demandado pelos habitantes.

Aplicação:

Área de indústria de saneamento



Case: Ocupação Hoteleira

1. INTRODUÇÃO | SÉRIES TEMPORAIS

12

Exemplo:

Predizer o percentual de ocupação de vagas em hotéis no próximo final de ano, tomando como referência os dados dos finais de anos anteriores, a fim de planejar a gestão de reservas e ajustar preços de forma mais adequada.

Aplicação:

Área de hotelaria





O Que é uma Série Temporal?

1. INTRODUÇÃO | SÉRIES TEMPORAIS

13

Uma **série temporal** consiste em um conjunto de observações de uma variável, em geral quantitativa, indexadas pelo **tempo**.

Exemplos:

- Cotações diárias do dólar comercial, entre 01/01/2015 e 31/12/2023.
- Faturamento mensal bruto da empresa, entre janeiro e dezembro de 2023.
- Condição climática diária em uma cidade (ensolarado, chuvoso ou nublado), nos últimos 14 dias.

Diferentemente de bases de dados em formato de **seção transversal**, com as quais trabalhamos nos modelos de regressão e árvore de decisão, as observações de uma série temporal possuem **alto grau de dependência** entre si. Por isso, as técnicas que vimos anteriormente não são adequadas para dados temporais.




2. Objetivo



Objetivo

2. OBJETIVO | SÉRIES TEMPORAIS

15




Nosso objetivo principal em modelagem de séries temporais consiste em **projetar** os valores mais plausíveis de uma série para momentos **futuros**, a partir do comportamento demonstrado no passado.



Objetivo

2. OBJETIVO | SÉRIES TEMPORAIS

16



Nosso objetivo principal em modelagem de séries temporais consiste em **projetar** os valores mais plausíveis de uma série para momentos **futuros**, a partir do comportamento demonstrado no passado.



3. Componentes da Série




Componentes de uma Série Temporal

3. COMPONENTES DA SÉRIE | SÉRIES TEMPORAIS


18

Tendência




Esta série temporal apresenta **tendência crescente**, pois os valores crescem ao longo do tempo. A tendência também pode ser **decrecente**.

Sazonalidade




Esta série temporal apresenta **sazonalidade**, pois ocorrem padrões de oscilação em instantes **igualmente espaçados** no tempo.


Tendência e Sazonalidade



Esta série temporal apresenta **tendência e sazonalidade**, pois os valores crescem ao longo do tempo e apresentam picos igualmente espaçados.



Estacionariedade



- Quanto a série temporal **não** apresenta tendência nem sazonalidade, dizemos que ela é **estacionária**.
- Em uma série estacionária, os valores oscilam em torno de uma **média constante**, com **variabilidade constante**.
- Alguns dos **modelos** que vamos estudar só podem ser utilizados para séries temporais estacionárias. Por isso, é importante avaliar se a série atende ou não a este requisito.
- Podemos fazer isso por meio de um teste de hipóteses chamado **Teste de Dickey-Fuller Generalizado (DF-GLS)**.




Teste de Dickey-Fuller Generalizado (DF-GLS)

3. COMPONENTES DA SÉRIE | SÉRIES TEMPORAIS

20

Estacionaridade



- Os cálculos por trás da estatística do **Teste de Dickey-Fuller Generalizado (DF-GLS)** se baseiam na tentativa de explicar os valores de uma série temporal a partir de diferenças em relação aos valores anteriores, como em uma **regressão**.
- As hipóteses testadas são:
 - **H**: a série é **não-estacionária**
 - **A**: a série é **estacionária**
- Caso o valor da estatística do teste seja inferior aos valores críticos (em geral, 5% ou 10%), **rejeitamos a hipótese H** e concluímos que a série é estacionária.



Case: Preços Diários de Ação


3. COMPONENTES DA SÉRIE | SÉRIES TEMPORAIS

21

Um investidor deseja prever quais serão os **preços** de uma determinada ação nos próximos **3 dias úteis**, com base no histórico dos últimos 90 dias úteis.



DIA_UTIL	PRECO_ACAO
1	14,82
2	15,68
3	15,91
4	15,01
5	14,24
6	14,01
7	14,42
8	14,82
9	15,27
10	15,07
...	...



A série é estacionária?

Arquivo: Precos_Acao (.txt)

@LABDATA FIA. Copyright all rights reserved.



Case: Preços Diários de Ação

3. COMPONENTES DA SÉRIE | SÉRIES TEMPORAIS

22

Um investidor deseja prever quais serão os **preços** de uma determinada ação nos próximos **3 dias úteis**, com base no histórico dos últimos 90 dias úteis.



```
> summary(ur.ers(serie))

#####
# Elliot, Rothenberg and Stock Unit Root Test #
#####

Test of type DF-GLS
detrending of series with intercept

Value of test-statistic is: -3.3382

Critical values of DF-GLS are:
critical values 1pct 5pct 10pct
                -2.59 -1.94 -1.62
```

O teste DF-GLS forneceu uma estatística de teste de **-3,3382**, inferior ao valor crítico de 1% (**-2,59**). Isso indica que o **p-valor** do teste seria **inferior a 1%**. Assim, concluímos que os preços da ação oscilaram em torno de uma média constante, com variabilidade constante, no período analisado.

Arquivo: Precos_Acao (.txt)

@LABDATA FIA. Copyright all rights reserved.



4. Modelos para Séries Estacionárias




Como Modelar uma Série Estacionária?

4. MODELOS PARA SÉRIES ESTACIONÁRIAS | SÉRIES TEMPORAIS

24

- Quando uma série é estacionária, a **modelagem** do comportamento histórico e **previsão** do comportamento futuro são mais simples, dado que não precisamos modelar tendências e sazonalidades.
- Os modelos mais comuns para séries estacionárias são:
 - **AR**: modelo autorregressivo (*autoregressive*)
 - **MA**: modelo de médias móveis (*moving average*)
 - **ARMA**: modelo autorregressivo de médias móveis
- Todos esses modelos são chamados **lineares** pois modelam os valores da série como uma combinação linear de comportamentos observados no passado.



Modelo Autorregressivo (AR)

4. MODELOS PARA SÉRIES ESTACIONÁRIAS | SÉRIES TEMPORAIS

25

O **modelo autorregressivo** (AR) consiste em estabelecer que o valor da série no instante de tempo t depende linearmente dos valores em instantes de tempo anteriores: $t - 1$, $t - 2$, $t - 3$ etc.

$$Y_t = \phi_1 Y_{t-1} + \dots + \phi_p Y_{t-p} + \epsilon_t$$

- Y_t é o valor da série no instante t
- Y_{t-1}, \dots, Y_{t-p} são os valores da série nos instantes anteriores $t - 1, \dots, t - p$
- ϕ_1, \dots, ϕ_p são os parâmetros associados aos valores Y_{t-1}, \dots, Y_{t-p}
- ϵ_t é o erro aleatório associado ao modelo no instante t , com média 0 e variância constante

* Letra grega ϕ : lê-se como 'fi'

* Letra grega ϵ : lê-se como 'épsilon'



Modelo Autorregressivo (AR)

4. MODELOS PARA SÉRIES ESTACIONÁRIAS | SÉRIES TEMPORAIS

26

O **modelo autorregressivo** (AR) consiste em estabelecer que o valor da série no instante de tempo t depende linearmente dos valores em instantes de tempo anteriores: $t - 1$, $t - 2$, $t - 3$ etc.

$$Y_t = \phi_1 Y_{t-1} + \dots + \phi_p Y_{t-p} + \epsilon_t$$

A quantidade de instantes passados é chamada **ordem do modelo AR**, e denotada pela letra p .

Exemplos:

- Modelo AR($p = 1$) ou AR(1): $Y_t = \phi_1 Y_{t-1} + \epsilon_t$
- Modelo AR($p = 2$) ou AR(2): $Y_t = \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \epsilon_t$
- Modelo AR($p = 5$) ou AR(5): $Y_t = \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \phi_3 Y_{t-3} + \phi_4 Y_{t-4} + \phi_5 Y_{t-5} + \epsilon_t$

* Letra grega ϕ : lê-se como 'fi'

* Letra grega ϵ : lê-se como 'épsilon'



Modelo de Médias Móveis (MA)

4. MODELOS PARA SÉRIES ESTACIONÁRIAS | SÉRIES TEMPORAIS

27

O **modelo de médias móveis** (MA) consiste em estabelecer que o valor da série no instante de tempo t corresponde a uma média constante μ , acrescida de uma combinação linear de erros ao redor de μ em instantes de tempo anteriores: $t - 1$, $t - 2$, $t - 3$ etc.

$$Y_t = \mu + \epsilon_t + \theta_1 \epsilon_{t-1} + \dots + \theta_q \epsilon_{t-q}$$

- Y_t é o valor da série no instante t
- μ é a média constante da série
- ϵ_t é o erro aleatório em torno de μ no instante t , com média 0 e variância constante
- $\epsilon_{t-1}, \dots, \epsilon_{t-q}$ são os erros aleatórios em torno de μ nos instantes $t - 1, \dots, t - q$, com média 0 e variância constante
- $\theta_1, \dots, \theta_q$ são os parâmetros associados aos erros $\epsilon_{t-1}, \dots, \epsilon_{t-q}$

* Letra grega μ : lê-se como 'mi'

* Letra grega θ : lê-se como 'téta'

* Letra grega ϵ : lê-se como 'épsilon'



Modelo de Médias Móveis (MA)

4. MODELOS PARA SÉRIES ESTACIONÁRIAS | SÉRIES TEMPORAIS

28

O **modelo de médias móveis** (MA) consiste em estabelecer que o valor da série no instante de tempo t corresponde a uma média constante μ , acrescida de uma combinação linear de erros ao redor de μ em instantes de tempo anteriores: $t - 1$, $t - 2$, $t - 3$ etc.

$$Y_t = \mu + \epsilon_t + \theta_1 \epsilon_{t-1} + \dots + \theta_q \epsilon_{t-q}$$

A quantidade de instantes passados é chamada **ordem do modelo MA**, e denotada pela letra q .

Exemplos:

- Modelo MA($q = 1$) ou MA(1): $Y_t = \mu + \epsilon_t + \theta_1 \epsilon_{t-1}$
- Modelo MA($q = 2$) ou MA(2): $Y_t = \mu + \epsilon_t + \theta_1 \epsilon_{t-1} + \theta_2 \epsilon_{t-2}$
- Modelo MA($q = 5$) ou MA(5): $Y_t = \mu + \epsilon_t + \theta_1 \epsilon_{t-1} + \theta_2 \epsilon_{t-2} + \theta_3 \epsilon_{t-3} + \theta_4 \epsilon_{t-4} + \theta_5 \epsilon_{t-5}$

* Letra grega μ : lê-se como 'mi'

* Letra grega θ : lê-se como 'téta'

* Letra grega ϵ : lê-se como 'épsilon'



Modelo Autorregressivo de Médias Móveis (ARMA)

O **modelo autorregressivo de médias móveis** (ARMA) consiste em estabelecer que o valor da série no instante de tempo t depende linearmente dos valores em instantes de tempo anteriores, acrescidos de uma combinação linear de erros em instantes de tempo anteriores: $t - 1$, $t - 2$, $t - 3$ etc.

$$Y_t = \phi_1 Y_{t-1} + \dots + \phi_p Y_{t-p} + \epsilon_t + \theta_1 \epsilon_{t-1} + \dots + \theta_q \epsilon_{t-q}$$

- Y_t é o valor da série no instante t
- Y_{t-1}, \dots, Y_{t-p} são os valores da série nos instantes anteriores $t - 1, \dots, t - p$ (cumprem o papel de μ)
- ϕ_1, \dots, ϕ_p são os parâmetros associados aos valores Y_{t-1}, \dots, Y_{t-p}
- ϵ_t é o erro aleatório associado à parte autorregressiva no instante t , com média 0 e variância constante
- $\epsilon_{t-1}, \dots, \epsilon_{t-q}$ são os erros aleatórios em torno da parte autorregressiva nos instantes $t - 1, \dots, t - q$, com média 0 e variância constante
- $\theta_1, \dots, \theta_q$ são os parâmetros associados aos erros $\epsilon_{t-1}, \dots, \epsilon_{t-q}$

* Letra grega ϕ : lê-se como 'fí'

* Letra grega θ : lê-se como 'téta'

* Letra grega ϵ : lê-se como 'épsilon'



Modelo Autorregressivo de Médias Móveis (ARMA)

4. MODELOS PARA SÉRIES ESTACIONÁRIAS | SÉRIES TEMPORAIS

30

O **modelo autorregressivo de médias móveis** (ARMA) consiste em estabelecer que o valor da série no instante de tempo t depende linearmente dos valores em instantes de tempo anteriores, acrescidos de uma combinação linear de erros em instantes de tempo anteriores: $t - 1$, $t - 2$, $t - 3$ etc.

$$Y_t = \phi_1 Y_{t-1} + \dots + \phi_p Y_{t-p} + \epsilon_t + \theta_1 \epsilon_{t-1} + \dots + \theta_q \epsilon_{t-q}$$

Ou seja, o modelo ARMA é uma junção dos modelos AR e MA. As **ordens do modelo** são denotadas por **p** e **q** .

Exemplos:

- Modelo ARMA($p = 1$, $q = 1$) ou ARMA(1,1): $Y_t = \phi_1 Y_{t-1} + \epsilon_t + \theta_1 \epsilon_{t-1}$
- Modelo ARMA($p = 1$, $q = 2$) ou ARMA(1,2): $Y_t = \phi_1 Y_{t-1} + \epsilon_t + \theta_1 \epsilon_{t-1} + \theta_2 \epsilon_{t-2}$
- Modelo ARMA($p = 2$, $q = 2$) ou ARMA(2,2): $Y_t = \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \epsilon_t + \theta_1 \epsilon_{t-1} + \theta_2 \epsilon_{t-2}$

* Letra grega ϕ : lê-se como 'fi'

* Letra grega θ : lê-se como 'téta'

* Letra grega ϵ : lê-se como 'épsilon'



Case: Preços Diários de Ação


4. MODELOS PARA SÉRIES ESTACIONÁRIAS | SÉRIES TEMPORAIS

31

Um investidor deseja prever quais serão os **preços** de uma determinada ação nos próximos **3 dias úteis**, com base no histórico dos últimos 90 dias úteis.



Preços diários da ação



➤ Qual o melhor modelo para esta série?

Arquivo: Precos_Acao (.txt)

@LABDATA FIA. Copyright all rights reserved.



Case: Preços Diários de Ação


4. MODELOS PARA SÉRIES ESTACIONÁRIAS | SÉRIES TEMPORAIS

32

Um investidor deseja prever quais serão os **preços** de uma determinada ação nos próximos **3 dias úteis**, com base no histórico dos últimos 90 dias úteis.



Preços diários da ação



➤ Qual o melhor modelo para esta série?

A função ***auto.arima*** do pacote ***forecast*** do R nos ajuda a identificar o melhor modelo para uma série estacionária (AR, MA ou ARMA), bem como a sua ordem.

A identificação do melhor modelo é feita por meio de testes baseados no padrão de **correlação** entre os valores históricos, a depender da distância (*lag*) entre eles.

Arquivo: Precos_Acao (.txt)

@LABDATA FIA. Copyright all rights reserved.



Case: Preços Diários de Ação


4. MODELOS PARA SÉRIES ESTACIONÁRIAS | SÉRIES TEMPORAIS

33

Um investidor deseja prever quais serão os **preços** de uma determinada ação nos próximos **3 dias úteis**, com base no histórico dos últimos 90 dias úteis.



Preços diários da ação



➤ Qual o melhor modelo para esta série?

```
> modelo <- auto.arima(base_precos$PRECO_ACAO)
> print(modelo)
Series: base_precos$PRECO_ACAO
ARIMA(2,0,2) with non-zero mean

Coefficients:
          ar1          ar2          ma1          ma2          mean
          1.1288      -0.8777      -0.4721      0.3888      14.9700
s.e.        0.0758        0.0655        0.1329        0.1257        0.0336

sigma^2 = 0.071:  log likelihood = -7.13
AIC=26.26   AICc=27.27   BIC=41.26
```

Arquivo: Precos_Acao (.txt)

@LABDATA FIA. Copyright all rights reserved.



Case: Preços Diários de Ação


4. MODELOS PARA SÉRIES ESTACIONÁRIAS | SÉRIES TEMPORAIS

34

Um investidor deseja prever quais serão os **preços** de uma determinada ação nos próximos **3 dias úteis**, com base no histórico dos últimos 90 dias úteis.



Preços diários da ação



➤ Qual o melhor modelo para esta série?

```
> modelo <- auto.arima(base_precos$PRECO_ACAO)
> print(modelo)
```

Series: base_precos\$PRECO_ACAO
ARIMA(2,0,2) with non-zero mean

Coefficients:

	ar1	ar2	ma1	ma2	mean
	1.1288	-0.8777	-0.4721	0.3888	14.9700
s.e.	0.0758	0.0655	0.1329	0.1257	0.0336

sigma² = 0.071: log likelihood = -7.13
AIC=26.26 AICc=27.27 BIC=41.26

2 termos AR

Arquivo: Precos_Acao (.txt)

@LABDATA FIA. Copyright all rights reserved.



Case: Preços Diários de Ação


4. MODELOS PARA SÉRIES ESTACIONÁRIAS | SÉRIES TEMPORAIS

35

Um investidor deseja prever quais serão os **preços** de uma determinada ação nos próximos **3 dias úteis**, com base no histórico dos últimos 90 dias úteis.



Preços diários da ação



➤ Qual o melhor modelo para esta série?

```
> modelo <- auto.arima(base_precos$PRECO_ACAO)
> print(modelo)
Series: base_precos$PRECO_ACAO
ARIMA(2,0,2) with non-zero mean

Coefficients:
          ar1          ar2          ma1          ma2          mean
      1.1288   -0.8777   -0.4721    0.3888   14.9700
s.e.  0.0758    0.0655    0.1329    0.1257    0.0336

sigma^2 = 0.071:  log likelihood = -7.13
AIC=26.26   AICc=27.27   BIC=41.26
```

2 termos MA

Arquivo: Precos_Acao (.txt)

@LABDATA FIA. Copyright all rights reserved.



Case: Preços Diários de Ação


4. MODELOS PARA SÉRIES ESTACIONÁRIAS | SÉRIES TEMPORAIS

36

Um investidor deseja prever quais serão os **preços** de uma determinada ação nos próximos **3 dias úteis**, com base no histórico dos últimos 90 dias úteis.



Preços diários da ação



➤ Qual o melhor modelo para esta série?

```
> modelo <- auto.arima(base_precos$PRECO_ACAO)
> print(modelo)
Series: base_precos$PRECO_ACAO
ARIMA(2,0,2) with non-zero mean


Coefficients:
          ar1      ar2      ma1      ma2      mean
    1.1288 -0.8777 -0.4721  0.3888 14.9700
s.e.  0.0      0.0      0.1      0.1    0.0336
       $\phi_1$        $\phi_2$        $\theta_1$        $\theta_2$ 

sigma^2 = 0.071: log likelihood = -7.13
AIC=26.26   AICc=27.27   BIC=41.26
```

Estimativas
do modelo
ARMA, com
 $p = 2$ e $q = 2$

Arquivo: Precos_Acao (.txt)

@LABDATA FIA. Copyright all rights reserved.



Case: Preços Diários de Ação


4. MODELOS PARA SÉRIES ESTACIONÁRIAS | SÉRIES TEMPORAIS

37

Um investidor deseja prever quais serão os **preços** de uma determinada ação nos próximos **3 dias úteis**, com base no histórico dos últimos 90 dias úteis.



Preços diários da ação



Aplicando o modelo na base de dados, podemos construir um **gráfico comparativo** dos valores reais observados *versus* valores preditos pelo modelo (ao lado).

Para avaliar a qualidade do modelo, é comum utilizar o índice **REQM**, que é a raiz quadrada do erro quadrático médio:

$$\text{REQM} = \sqrt{\frac{1}{n} \sum_{t=1}^n (Y_t - \hat{Y}_t)^2}$$

Valores preditos

Valores reais

Arquivo: Precos_Acao (.txt)

@LABDATA FIA. Copyright all rights reserved.



Case: Preços Diários de Ação


4. MODELOS PARA SÉRIES ESTACIONÁRIAS | SÉRIES TEMPORAIS

38

Um investidor deseja prever quais serão os **preços** de uma determinada ação nos próximos **3 dias úteis**, com base no histórico dos últimos 90 dias úteis.



Preços diários da ação



Neste *case*, **REQM = 0,259**.

Ou seja, os valores preditos pelo modelo desviam-se dos valores reais em cerca de **26 centavos**, em média.

Arquivo: Precos_Acao (.txt)

@LABDATA FIA. Copyright all rights reserved.



Case: Preços Diários de Ação


4. MODELOS PARA SÉRIES ESTACIONÁRIAS | SÉRIES TEMPORAIS

39

Um investidor deseja prever quais serão os **preços** de uma determinada ação nos próximos **3 dias úteis**, com base no histórico dos últimos 90 dias úteis.



Preços diários da ação



Projetando a fórmula do modelo estimado para os próximos 3 dias úteis, obtemos as seguintes **previsões** (destacadas como pontos **vermelhos** no gráfico ao lado):

- ✓ Dia 91: **R\$ 14,57**
- ✓ Dia 92: **R\$ 14,89**
- ✓ Dia 93: **R\$ 15,22**

Ou seja, estimamos que haverá **aumento** no preço da ação nos próximos dias.

Arquivo: Precos_Acao (.txt)

@LABDATA FIA. Copyright all rights reserved.



Funções de Autocorrelação e Autocorrelação Parcial (tópico extra)

4. MODELOS PARA SÉRIES ESTACIONÁRIAS | SÉRIES TEMPORAIS

40

Uma outra forma de identificar modelos para séries estacionárias é por meio da **função de autocorrelação** (ACF) e da **função de autocorrelação parcial** (PACF) associadas a uma série temporal.



Funções de Autocorrelação e Autocorrelação Parcial (tópico extra)

4. MODELOS PARA SÉRIES ESTACIONÁRIAS | SÉRIES TEMPORAIS

41

- **Autocorrelação:** Índice que mede a associação linear entre os valores da série em um instante t e os valores em um instante $t - k$. O valor k é chamado defasagem, ou simplesmente *lag*.

Exemplos:

- A autocorrelação para *lag* $k = 1$ corresponde ao grau de associação linear entre os pares $(x_t, x_{t-1}), (x_{t-1}, x_{t-2}), \dots$
- A autocorrelação para *lag* $k = 4$ corresponde ao grau de associação linear entre os pares $(x_t, x_{t-4}), (x_{t-1}, x_{t-5}), \dots$

A **função de autocorrelação** (ACF) é uma função que, para cada valor de *lag* k , associa o valor do índice de autocorrelação associado aos pares de valores da série defasados em k instantes.

É comum representar a função de autocorrelação por meio de um **gráfico de linhas verticais**, como veremos a seguir.



- **Autocorrelação parcial:** Índice que mede a associação linear remanescente entre os valores da série em um instante t e os valores em um instante $t - k$, dados os valores de instantes intermediários $t - 1, t - 2, \dots, t - (k - 1)$. Pode ser compreendida como o grau de informação adicional que o valor de k instantes anteriores fornece sobre o valor de um determinado instante, que não é explicado pelos valores dos $k - 1$ instantes mais recentes.

Exemplos:

- A autocorrelação para $lag\ k = 2$ corresponde ao grau de associação linear entre os pares $(x_t, x_{t-2}), (x_{t-1}, x_{t-3}), \dots$, sem considerar a influência já embutida no valor de 1 instante atrás ($lag\ k = 1$).
- A autocorrelação para $lag\ k = 5$ corresponde ao grau de associação linear entre os pares $(x_t, x_{t-5}), (x_{t-1}, x_{t-6}), \dots$, sem considerar a influência já embutida nos valores de 1 a 4 instantes atrás ($lags\ k = 1, 2, 3, 4$).

A **função de autocorrelação parcial** (PACF) é uma função que, para cada valor de $lag\ k$, associa o valor do índice de autocorrelação parcial associado aos pares de valores da série defasados em k instantes.

Também é comum representar a função de autocorrelação parcial por meio de um **gráfico de linhas verticais**, como veremos a seguir.

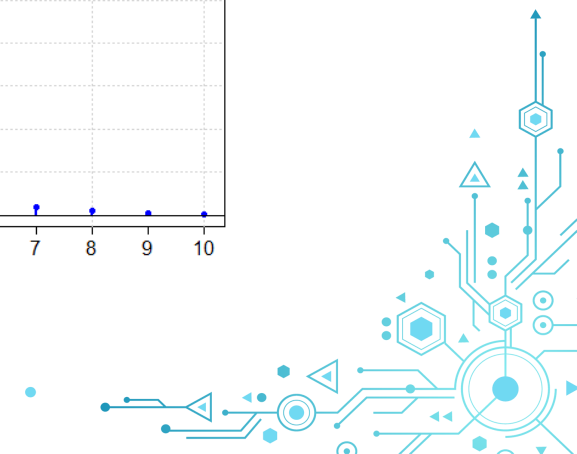


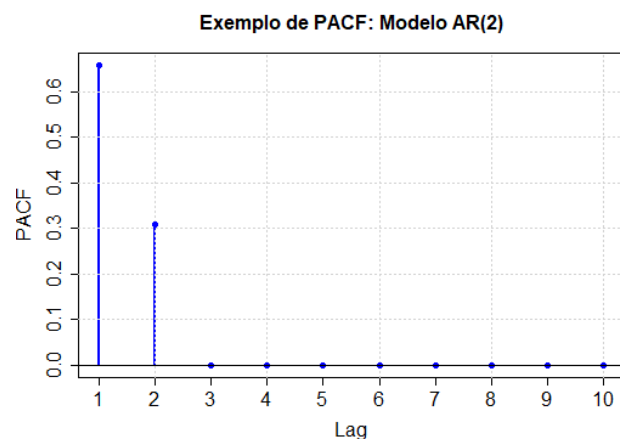
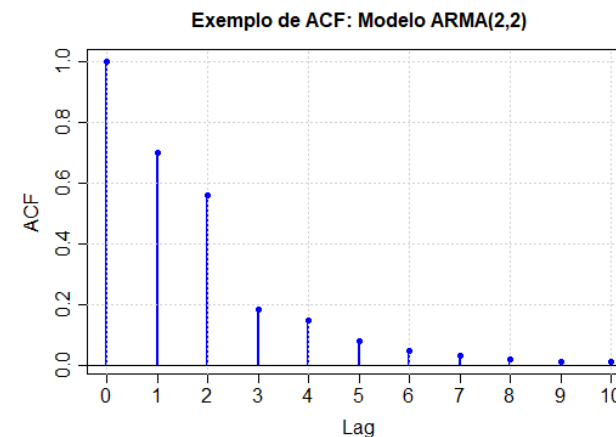




Funções de Autocorrelação e Autocorrelação Parcial (tópico extra)

4. MODELOS PARA SÉRIES ESTACIONÁRIAS | SÉRIES TEMPORAIS

43

Comportamento típico dos gráficos de ACF e PACF para modelos AR(2), MA(2) e ARMA(2,2).

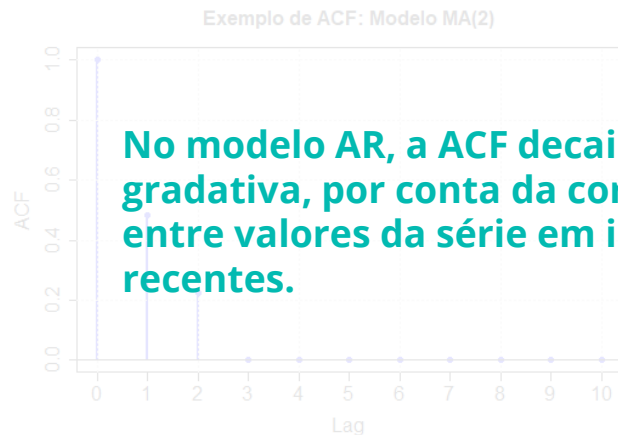
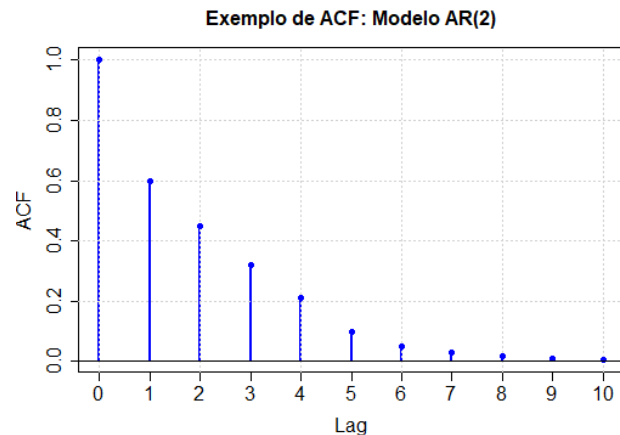


Funções de Autocorrelação e Autocorrelação Parcial (tópico extra)


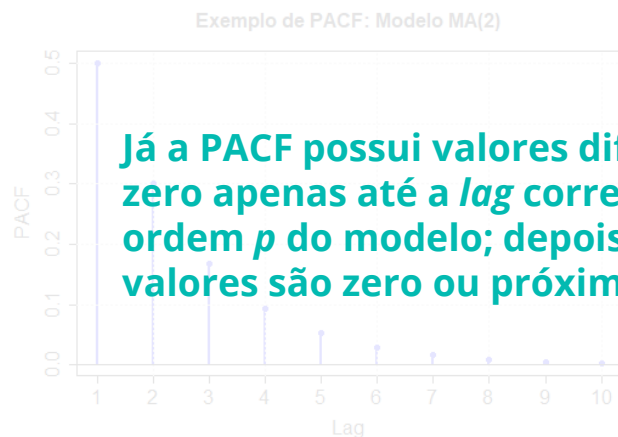

4. MODELOS PARA SÉRIES ESTACIONÁRIAS | SÉRIES TEMPORAIS

44

Comportamento típico dos gráficos de ACF e PACF para modelos AR(2), MA(2) e ARMA(2,2).



No modelo AR, a ACF decai de forma gradativa, por conta da correlação entre valores da série em instantes recentes.



Já a PACF possui valores diferentes de zero apenas até a lag corresponde à ordem p do modelo; depois disso, os valores são zero ou próximos de zero.




Funções de Autocorrelação e Autocorrelação Parcial (tópico extra)

4. MODELOS PARA SÉRIES ESTACIONÁRIAS | SÉRIES TEMPORAIS


45

Comportamento típico dos gráficos de ACF e PACF para modelos AR(2), MA(2) e ARMA(2,2).


Exemplo de ACF: Modelo AR(2)



Exemplo de ACF: Modelo MA(2)



Exemplo de ACF: Modelo ARMA(2,2)




No modelo MA, a ACF possui valores diferentes de zero apenas até a *lag* corresponde à ordem q do modelo; depois disso, os valores são zero ou próximos de zero.


Exemplo de PACF: Modelo AR(2)



Exemplo de PACF: Modelo MA(2)



Exemplo de PACF: Modelo ARMA(2,2)



Já a PACF decai de forma gradativa, por conta da correlação entre valores da série e os erros de instantes recentes.

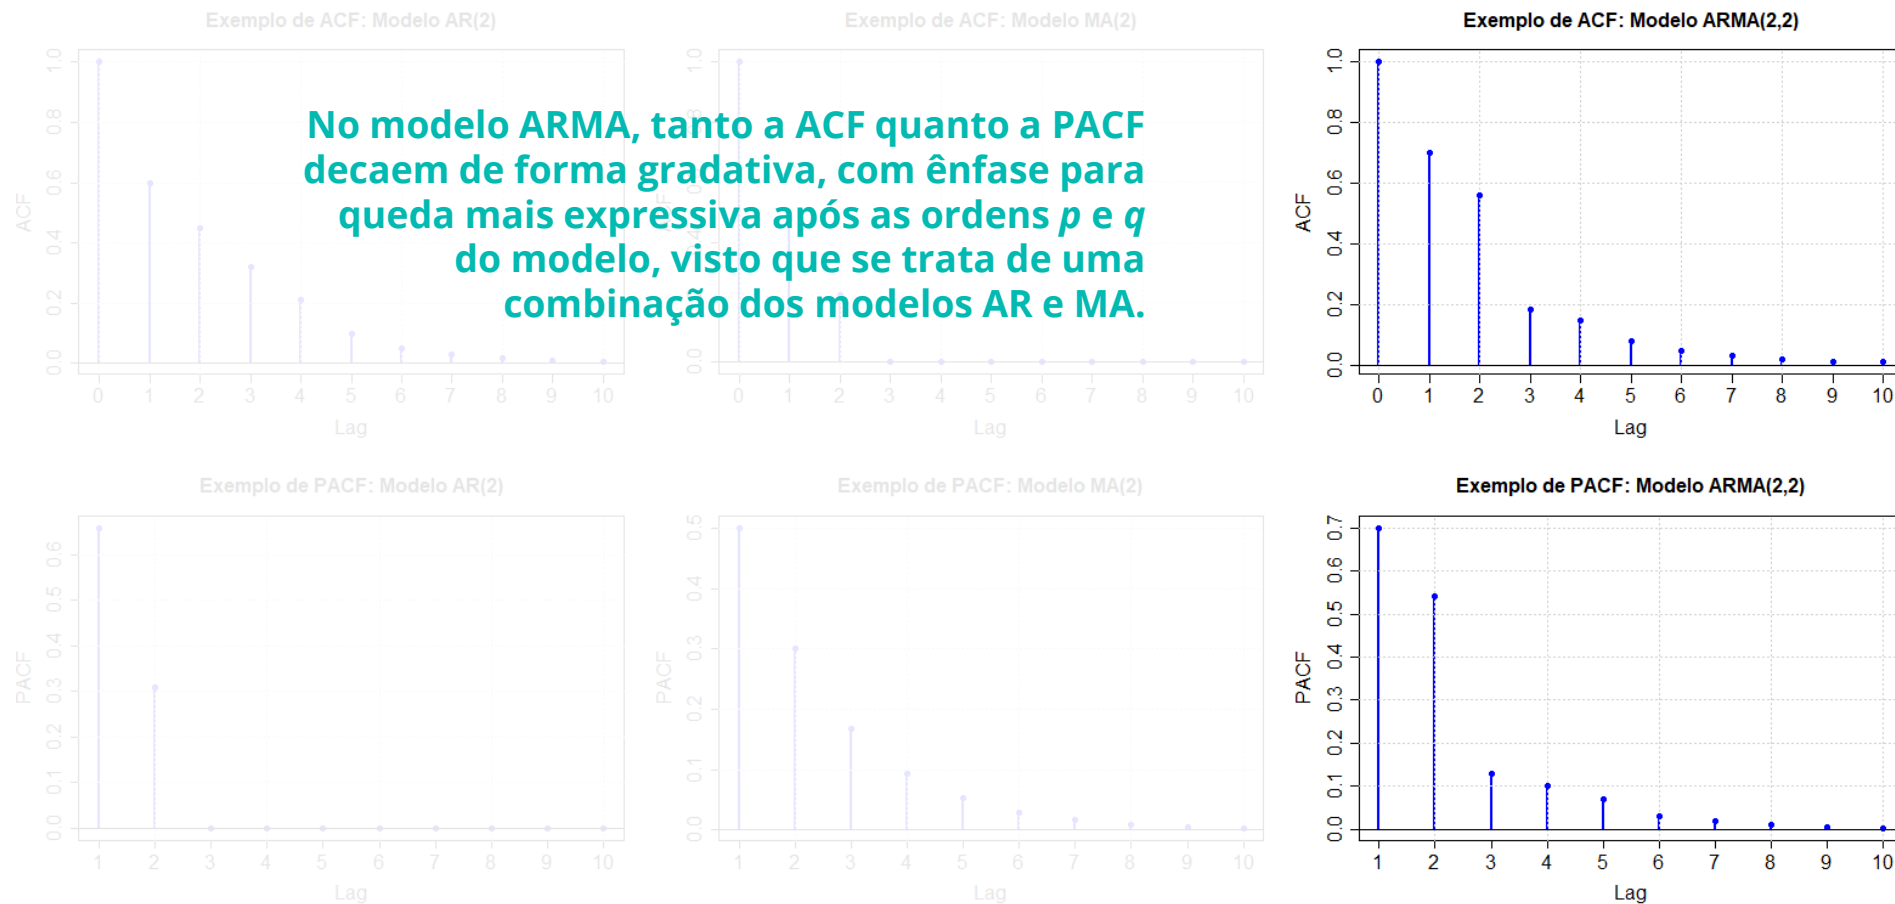


Funções de Autocorrelação e Autocorrelação Parcial (tópico extra)

4. MODELOS PARA SÉRIES ESTACIONÁRIAS | SÉRIES TEMPORAIS

46

Comportamento típico dos gráficos de ACF e PACF para modelos AR(2), MA(2) e ARMA(2,2).



5. Modelos para Séries Não Estacionárias




Como Modelar uma Série Não Estacionária?

5. MODELOS PARA SÉRIES NÃO ESTACIONÁRIAS | SÉRIES TEMPORAIS

48

- Quando uma série não é estacionária, a **modelagem** do comportamento histórico e **previsão** do comportamento futuro envolvem aplicar transformações para que a série se torne estacionária e possa, então, ser explicada pelos modelos que já estudamos: AR, MA, ARMA.
- Os modelos mais comuns para séries não estacionárias são:
 - **ARIMA**: modelo autorregressivo de média móveis integrado
 - **SARIMA**: modelo autorregressivo de média móveis integrado sazonal




Como Modelar uma Série Não Estacionária?

5. MODELOS PARA SÉRIES NÃO ESTACIONÁRIAS | SÉRIES TEMPORAIS

49

- Quando uma série não é estacionária, a **modelagem** do comportamento histórico e **previsão** do comportamento futuro envolvem aplicar transformações para que a série se torne estacionária e possa, então, ser explicada pelos modelos que já estudamos: AR, MA, ARMA.
- Os modelos mais comuns para séries não estacionárias são:
 - **ARIMA**: modelo autorregressivo de média móveis integrado
 - **SARIMA**: modelo autorregressivo de média móveis integrado sazonal

Estes modelos são generalizações do modelo **ARMA** para séries que possuem tendência e/ou sazonalidade



Modelo Autorregressivo de Médias Móveis Integrado (ARIMA)

5. MODELOS PARA SÉRIES NÃO ESTACIONÁRIAS | SÉRIES TEMPORAIS

50

O **modelo autorregressivo de médias móveis integrado** (ARIMA) consiste em um modelo ARMA aplicado após um tratamento da série original, realizado para remover o componente de **tendência**. Este tratamento é chamado **integração** (ou *diferenciação*), cuja inicial motiva o acréscimo da letra **I** à sigla.

A integração consiste em definir uma nova série Z_t cujos valores são as **diferenças** entre valores consecutivos da série original Y_t , ou seja:

$$Z_t = Y_t - Y_{t-1}$$

Em muitos casos, realizar este tratamento já é suficiente para **remover as tendências** e tornar Z_t uma série **estacionária**, sobre a qual o modelo ARMA poderá ser aplicado.

Caso as tendências da série original possuam um comportamento mais complexo, pode ocorrer de uma única integração não ser suficiente para tornar a série estacionária. Neste caso, **novas integrações** podem ser realizadas, de forma cumulativa. Por exemplo, a segunda integração seria:

$$Z_t - Z_{t-1}$$




Modelo Autorregressivo de Médias Móveis Integrado (ARIMA)

5. MODELOS PARA SÉRIES NÃO ESTACIONÁRIAS | SÉRIES TEMPORAIS


51

Exemplos:


Exemplo 1: Série com tendência




Exemplo 1: Série diferenciada




Exemplo 2: Série com tendência





Exemplo 2: Série diferenciada



Exemplo 3: Série com tendência



Exemplo 3: Série diferenciada




Modelo Autorregressivo de Médias Móveis Integrado (ARIMA)

5. MODELOS PARA SÉRIES NÃO ESTACIONÁRIAS | SÉRIES TEMPORAIS


52

Exemplos:

Exemplo 1: Série com tendência




Exemplo 1: Série diferenciada




Exemplo 2: Série com tendência



Exemplo 2: Série diferenciada





Exemplo 3: Série com tendência



A segunda diferenciação parece necessária aqui

Exemplo 3: Série diferenciada duas vezes



Modelo Autorregressivo de Médias Móveis Integrado (ARIMA)

5. MODELOS PARA SÉRIES NÃO ESTACIONÁRIAS | SÉRIES TEMPORAIS

53

Dessa forma, o **modelo autorregressivo de médias móveis integrado** (ARIMA) é dado por:

$$Z_t = \phi_1 Z_{t-1} + \dots + \phi_p Z_{t-p} + \epsilon_t + \theta_1 \epsilon_{t-1} + \dots + \theta_q \epsilon_{t-q}$$

sendo:


$$Z_t = (1 - B)^d Y_t$$

onde $(1 - B)$ é um símbolo que corresponde ao tratamento de **integração**, realizado **d** vezes cumulativas sobre a série original Y_t até que ela se torne estacionária.

As **ordens do modelo** são denotadas por **p** , **d** e **q** . O modelo *ARIMA* (**p, d, q**) é um modelo *ARMA* (**p, q**) com **d** operações de integração.

Exemplos:

- Modelo *ARIMA* ($p = 1, d = 1, q = 2$) ou *ARIMA* (1,1,2): $Z_t = \phi_1 Z_{t-1} + \epsilon_t + \theta_1 \epsilon_{t-1} + \theta_2 \epsilon_{t-2}$, onde $Z_t = (1 - B) Y_t$
- Modelo *ARIMA* ($p = 2, d = 2, q = 1$) ou *ARIMA* (2,2,1): $Z_t = \phi_1 Z_{t-1} + \phi_2 Z_{t-2} + \epsilon_t + \theta_1 \epsilon_{t-1}$, onde $Z_t = (1 - B)^2 Y_t$



Case: Carteira de Clientes


5. MODELOS PARA SÉRIES NÃO ESTACIONÁRIAS | SÉRIES TEMPORAIS

54

Uma empresa de serviços financeiros deseja projetar o volume de sua **carteira de clientes** para o mês seguinte, com base no histórico de 48 meses anteriores (mai/19 a abr/23).



Volume da carteira de clientes



➤ Qual o melhor modelo para esta série?

Arquivo: Carteira_Clientes (.txt)

@LABDATA FIA. Copyright all rights reserved.



Case: Carteira de Clientes


5. MODELOS PARA SÉRIES NÃO ESTACIONÁRIAS | SÉRIES TEMPORAIS

55

Uma empresa de serviços financeiros deseja projetar o volume de sua **carteira de clientes** para o mês seguinte, com base no histórico de 48 meses anteriores (mai/19 a abr/23).



Volume da carteira de clientes



➤ Qual o melhor modelo para esta série?

Novamente, a função ***auto.arima*** do pacote ***forecast*** do R nos ajuda a identificar o melhor modelo para uma série não estacionária (ARIMA), bem como a sua ordem.

A identificação do melhor modelo é feita por meio de testes baseados no padrão de **correlação** entre os valores históricos, a depender da distância (*lag*) entre eles.

Arquivo: Carteira_Clientes (.txt)

@LABDATA FIA. Copyright all rights reserved.



Case: Carteira de Clientes


5. MODELOS PARA SÉRIES NÃO ESTACIONÁRIAS | SÉRIES TEMPORAIS

56

Uma empresa de serviços financeiros deseja projetar o volume de sua **carteira de clientes** para o mês seguinte, com base no histórico de 48 meses anteriores (mai/19 a abr/23).



Volume da carteira de clientes



➤ Qual o melhor modelo para esta série?

```
> modelo <- auto.arima(base_clientes$QTDE_CLIENTES)
> print(modelo)
Series: base_clientes$QTDE_CLIENTES
ARIMA(1,1,2)

Coefficients:
          ar1          ma1          ma2
          0.9736       -1.6951       0.7852
s.e.        0.0391        0.1266       0.0977

sigma^2 = 391955: log likelihood = -369.02
AIC=746.05   AICc=747    BIC=753.45
```

Arquivo: Carteira_Clientes (.txt)

@LABDATA FIA. Copyright all rights reserved.



Case: Carteira de Clientes


5. MODELOS PARA SÉRIES NÃO ESTACIONÁRIAS | SÉRIES TEMPORAIS

57

Uma empresa de serviços financeiros deseja projetar o volume de sua **carteira de clientes** para o mês seguinte, com base no histórico de 48 meses anteriores (mai/19 a abr/23).



Volume da carteira de clientes



➤ Qual o melhor modelo para esta série?

```
> modelo <- auto.arima(base_clientes$QTDE_CLIENTES)
> print(modelo)
Series: base_clientes$QTDE_CLIENTES
ARIMA(1,1,2)

Coefficients:
    ar1    ma1    ma2
 0.9736 -1.6951  0.7852
s.e.  0.0391  0.1266  0.0977

sigma^2 = 391955: log likelihood = -369.02
AIC=746.05   AICc=747   BIC=753.45
```

1 termo AR

Arquivo: Carteira_Clientes (.txt)

@LABDATA FIA. Copyright all rights reserved.



Case: Carteira de Clientes


5. MODELOS PARA SÉRIES NÃO ESTACIONÁRIAS | SÉRIES TEMPORAIS

58

Uma empresa de serviços financeiros deseja projetar o volume de sua **carteira de clientes** para o mês seguinte, com base no histórico de 48 meses anteriores (mai/19 a abr/23).



Volume da carteira de clientes



➤ Qual o melhor modelo para esta série?

```
> modelo <- auto.arima(base_clientes$QTDE_CLIENTES)
> print(modelo)
Series: base_clientes$QTDE_CLIENTES
ARIMA(1,1,2)

Coefficients:
      ar1      ma1      ma2
  0.9736 -1.6951  0.7852
s.e.  0.0391  0.1266  0.0977

sigma^2 = 391955: log likelihood = -369.02
AIC=746.05  AICc=747   BIC=753.45
```

2 termos MA

Arquivo: Carteira_Clientes (.txt)

@LABDATA FIA. Copyright all rights reserved.



Case: Carteira de Clientes


5. MODELOS PARA SÉRIES NÃO ESTACIONÁRIAS | SÉRIES TEMPORAIS

59

Uma empresa de serviços financeiros deseja projetar o volume de sua **carteira de clientes** para o mês seguinte, com base no histórico de 48 meses anteriores (mai/19 a abr/23).



Volume da carteira de clientes



➤ Qual o melhor modelo para esta série?

```
> modelo <- auto.arima(base_clientes$QTDE_CLIENTES)
> print(modelo)
Series: base_clientes$QTDE_CLIENTES
ARIMA(1,1,2)
```

Coefficients:

	ar1	ma1	ma2
	0.9736	-1.6951	0.7852
s.e.	0.0391	0.1266	0.0977

```
sigma^2 = 391955: log likelihood = -369.02
AIC=746.05   AICc=747   BIC=753.45
```

1 integração

Arquivo: Carteira_Clientes (.txt)

@LABDATA FIA. Copyright all rights reserved.



Case: Carteira de Clientes


5. MODELOS PARA SÉRIES NÃO ESTACIONÁRIAS | SÉRIES TEMPORAIS

60

Uma empresa de serviços financeiros deseja projetar o volume de sua **carteira de clientes** para o mês seguinte, com base no histórico de 48 meses anteriores (mai/19 a abr/23).



Volume da carteira de clientes



➤ Qual o melhor modelo para esta série?

```
> modelo <- auto.arima(base_clientes$QTDE_CLIENTES)
> print(modelo)
Series: base_clientes$QTDE_CLIENTES
ARIMA(1,1,2)

Coefficients:
          ar1          ma1          ma2
      0.9736    -1.6951     0.7852
s.e.    0.0      0.1      0.0
       $\phi_1$        $\theta_1$        $\theta_2$ 

sigma^2 = 391955: log likelihood = -369.02
AIC=746.05   AICc=747   BIC=753.45
```

Estimativas do
modelo ARIMA, com
 $p = 1$, $d = 1$ e $q = 2$

Arquivo: Carteira_Clientes (.txt)

@LABDATA FIA. Copyright all rights reserved.



Case: Carteira de Clientes


5. MODELOS PARA SÉRIES NÃO ESTACIONÁRIAS | SÉRIES TEMPORAIS

61

Uma empresa de serviços financeiros deseja projetar o volume de sua **carteira de clientes** para o mês seguinte, com base no histórico de 48 meses anteriores (mai/19 a abr/23).



Volume da carteira de clientes



Aplicando o modelo na base de dados, podemos construir um **gráfico comparativo** dos valores reais observados *versus* valores preditos pelo modelo (ao lado).

Neste *case*, **REQM = 599,4**.

Ou seja, os valores preditos pelo modelo desviam-se dos valores reais em cerca de **599 clientes**, em média.

Arquivo: Carteira_Clientes (.txt)

@LABDATA FIA. Copyright all rights reserved.



Case: Carteira de Clientes


5. MODELOS PARA SÉRIES NÃO ESTACIONÁRIAS | SÉRIES TEMPORAIS

62

Uma empresa de serviços financeiros deseja projetar o volume de sua **carteira de clientes** para o mês seguinte, com base no histórico de 48 meses anteriores (mai/19 a abr/23).



Volume da carteira de clientes



Projetando a fórmula do modelo estimado para o próximo mês, obtemos a seguinte **previsão** (destacada como um ponto **vermelho** no gráfico ao lado):

✓ mai/23: **11.403 clientes**

Ou seja, estimamos que haverá **aumento** no volume de clientes no próximo mês, um pouco abaixo do recorde histórico de 11.494 clientes (observado no mês de fev/23).

Arquivo: Carteira_Clientes (.txt)

@LABDATA FIA. Copyright all rights reserved.



Modelo Autorregressivo de Médias Móveis Integrado Sazonal (SARIMA)

5. MODELOS PARA SÉRIES NÃO ESTACIONÁRIAS | SÉRIES TEMPORAIS

63

O **modelo autorregressivo de médias móveis integrado sazonal** (**S**ARIMA) consiste em um modelo ARMA aplicado após um tratamento da série original, realizado para remover os componentes de **sazonalidade e tendência**. O tratamento adicional em relação ao ARIMA é chamado **integração sazonal** (ou *diferenciação sazonal*), cuja inicial motiva o acréscimo da letra **S** à sigla.

A integração sazonal consiste em definir uma nova série Z_t cujos valores são as **diferenças** entre valores da série original Y_t defasados em **m** instantes de tempo; em geral, $m = 7$ dias, $m = 12$ meses etc. Ou seja:

$$Z_t = Y_t - Y_{t-m}$$

Em muitos casos, realizar a integração simples e a integração sazonal uma única vez (cada) já é suficiente para **remover sazonalidade e tendência** e tornar Z_t uma série **estacionária**, sobre a qual o modelo ARMA poderá ser aplicado. Porém, de forma geral, diremos que podem ser necessárias **d** integrações simples e **D** integrações sazonais.




Modelo Autorregressivo de Médias Móveis Integrado Sazonal (SARIMA)

5. MODELOS PARA SÉRIES NÃO ESTACIONÁRIAS | SÉRIES TEMPORAIS


64

Exemplos:


Exemplo 1: Série com sazonalidade




Exemplo 1: Série dessazonalizada ($m = 12$)





Exemplo 2: Série com tendência e sazonalidade



Exemplo 2: Série diferenciada



Exemplo 2: Série dessazonalizada ($m = 7$)



Modelo Autorregressivo de Médias Móveis Integrado Sazonal (SARIMA)

5. MODELOS PARA SÉRIES NÃO ESTACIONÁRIAS | SÉRIES TEMPORAIS

65

A equação do **modelo autorregressivo de médias móveis integrado sazonal** (SARIMA) é mais complexa que o ARIMA, devido ao fato de envolver integrações simples e sazonais de forma cumulativa. A série modelada será:

$$Z_t = (1 - B_m)^D (1 - B)^d Y_t$$

onde $(1 - B)$ é um símbolo que corresponde ao tratamento de **integração**, realizado **d** vezes cumulativas sobre a série original Y_t até remover a tendência, e $(1 - B_m)$ corresponde ao tratamento de **integração sazonal**, realizado **D** vezes cumulativas sobre a série diferenciada até remover a sazonalidade, com periodicidade m .

As **ordens do modelo** são denotadas por **p , d e q** , como no *ARIMA*, e **P , D e Q** , que equivalem aos respectivos componentes sazonais de autorregressão, integração e médias móveis.

Exemplos:

- Modelo *SARIMA* ($p = 1, d = 1, q = 2$) \times ($P = 1, D = 1, Q = 3$)¹² ou *SARIMA* (1,1,2) \times (1,1,3)¹²:
é semelhante ao modelo *ARIMA* (1,1,2), com acréscimo do termo (1,1,3)¹², que indica que a série original Y_t recebeu uma integração sazonal ($D = 1$), depende do valor de Y_{t-12} ($P = 1$) e depende dos erros de estimação de Y_{t-12} , Y_{t-24} e Y_{t-36} ($Q = 3$).



Case: Tráfego de Veículos


5. MODELOS PARA SÉRIES NÃO ESTACIONÁRIAS | SÉRIES TEMPORAIS

66

A concessionária de uma rodovia precisa estimar a quantidade mensal de **veículos** que trafegarão em determinado trecho no ano seguinte, com base em um histórico de 12 anos (jun/11 a mai/23).



Volume de tráfego de veículos



➤ Qual o melhor modelo para esta série?

Arquivo: Veiculos (.txt)

@LABDATA FIA. Copyright all rights reserved.



Case: Tráfego de Veículos


5. MODELOS PARA SÉRIES NÃO ESTACIONÁRIAS | SÉRIES TEMPORAIS

67

A concessionária de uma rodovia precisa estimar a quantidade mensal de **veículos** que trafegarão em determinado trecho no ano seguinte, com base em um histórico de 12 anos (jun/11 a mai/23).



Volume de tráfego de veículos



➤ Qual o melhor modelo para esta série?

Novamente, a função ***auto.arima*** do pacote ***forecast*** do R nos ajuda a identificar o melhor modelo para uma série não estacionária sazonal (SARIMA), bem como a sua ordem.

A identificação do melhor modelo é feita por meio de testes baseados no padrão de **correlação** entre os valores históricos, a depender da distância (*lag*) entre eles.

Arquivo: Veiculos (.txt)

@LABDATA FIA. Copyright all rights reserved.



Case: Tráfego de Veículos


5. MODELOS PARA SÉRIES NÃO ESTACIONÁRIAS | SÉRIES TEMPORAIS

68

A concessionária de uma rodovia precisa estimar a quantidade mensal de **veículos** que trafegarão em determinado trecho no ano seguinte, com base em um histórico de 12 anos (jun/11 a mai/23).



Volume de tráfego de veículos



➤ Qual o melhor modelo para esta série?

```
> modelo <- auto.arima(serie,
+                       seasonal = TRUE)
> print(modelo)
Series: serie
ARIMA(0,1,1)(0,1,1)[12]

Coefficients:
            ma1      sma1
            -0.8203  -0.4183
s.e.         0.0641   0.0751

sigma^2 = 6.79e+08: log likelihood = -1518.64
AIC=3043.29   AICc=3043.48   BIC=3051.91
```

Arquivo: Veiculos (.txt)

@LABDATA FIA. Copyright all rights reserved.



Case: Tráfego de Veículos


5. MODELOS PARA SÉRIES NÃO ESTACIONÁRIAS | SÉRIES TEMPORAIS

69

A concessionária de uma rodovia precisa estimar a quantidade mensal de **veículos** que trafegarão em determinado trecho no ano seguinte, com base em um histórico de 12 anos (jun/11 a mai/23).



Volume de tráfego de veículos



➤ Qual o melhor modelo para esta série?

```
> modelo <- auto.arima(serie,
+                        seasonal = TRUE)
> print(modelo)
Series: serie
ARIMA(0,1,1)(0,1,1)[12]

Coefficients:
    ma1    sma1
-0.8203 -0.4183
s.e.    0.0641  0.0751

sigma^2 = 6.79e+08: log likelihood = -1518.64
AIC=3043.29   AICc=3043.48   BIC=3051.91
```

1 termo MA

Arquivo: Veiculos (.txt)

@LABDATA FIA. Copyright all rights reserved.



Case: Tráfego de Veículos


5. MODELOS PARA SÉRIES NÃO ESTACIONÁRIAS | SÉRIES TEMPORAIS

70

A concessionária de uma rodovia precisa estimar a quantidade mensal de **veículos** que trafegarão em determinado trecho no ano seguinte, com base em um histórico de 12 anos (jun/11 a mai/23).



Volume de tráfego de veículos



➤ Qual o melhor modelo para esta série?

```
> modelo <- auto.arima(serie,
+                        seasonal = TRUE)
> print(modelo)
Series: serie
ARIMA(0,1,1)(0,1,1)[12]

Coefficients:
      ma1      sma1
    -0.8203  -0.4183
s.e.    0.0641   0.0751

sigma^2 = 6.79e+08:  log likelihood = -1518.64
AIC=3043.29   AICc=3043.48   BIC=3051.91
```

1 termo MA sazonal

Arquivo: Veiculos (.txt)

@LABDATA FIA. Copyright all rights reserved.



Case: Tráfego de Veículos


5. MODELOS PARA SÉRIES NÃO ESTACIONÁRIAS | SÉRIES TEMPORAIS

71

A concessionária de uma rodovia precisa estimar a quantidade mensal de **veículos** que trafegarão em determinado trecho no ano seguinte, com base em um histórico de 12 anos (jun/11 a mai/23).



Volume de tráfego de veículos



➤ Qual o melhor modelo para esta série?

```
> modelo <- auto.arima(serie,
+                        seasonal = TRUE)
> print(modelo)
Series: serie
ARIMA(0,1,1)(0,1,1)[12]

Coefficients:
          ma1      sma1
        -0.8203  -0.4183
s.e.      0.0641   0.0751

sigma^2 = 6.79e+08: log likelihood = -1518.64
AIC=3043.29   AICc=3043.48   BIC=3051.91
```

1 integração

Arquivo: Veiculos (.txt)

@LABDATA FIA. Copyright all rights reserved.



Case: Tráfego de Veículos


5. MODELOS PARA SÉRIES NÃO ESTACIONÁRIAS | SÉRIES TEMPORAIS

72

A concessionária de uma rodovia precisa estimar a quantidade mensal de **veículos** que trafegarão em determinado trecho no ano seguinte, com base em um histórico de 12 anos (jun/11 a mai/23).



Volume de tráfego de veículos



➤ Qual o melhor modelo para esta série?

```
> modelo <- auto.arima(serie,  
+                        seasonal = TRUE)  
> print(modelo)
```

```
Series: serie  
ARIMA(0,1,1)(0,1,1)[12]
```

Coefficients:

	ma1	sma1
	-0.8203	-0.4183
s.e.	0.0641	0.0751

```
sigma^2 = 6.79e+08: log likelihood = -1518.64  
AIC=3043.29 AICc=3043.48 BIC=3051.91
```

1 integração
sazonal, de
período 12

Arquivo: Veiculos (.txt)

@LABDATA FIA. Copyright all rights reserved.



Case: Tráfego de Veículos


5. MODELOS PARA SÉRIES NÃO ESTACIONÁRIAS | SÉRIES TEMPORAIS

73

A concessionária de uma rodovia precisa estimar a quantidade mensal de **veículos** que trafegarão em determinado trecho no ano seguinte, com base em um histórico de 12 anos (jun/11 a mai/23).



Volume de tráfego de veículos



➤ Qual o melhor modelo para esta série?

```
> modelo <- auto.arima(serie,  
+                        seasonal = TRUE)  
> print(modelo)
```

```
Series: serie  
ARIMA(0,1,1)(0,1,1)[12]
```

Coefficients:

	ma1	sma1
	-0.03	-0.03
s.e.	0.03	0.03

```
sigma^2 = 6.79e+08: log likelihood = -1518.64  
AIC=3043.29 AICc=3043.48 BIC=3051.91
```

Estimativas do modelo SARIMA, com
 $p = 0, d = 1, q = 1,$
 $P = 0, D = 1, Q = 1$

Arquivo: Veiculos (.txt)

@LABDATA FIA. Copyright all rights reserved.



Case: Tráfego de Veículos


5. MODELOS PARA SÉRIES NÃO ESTACIONÁRIAS | SÉRIES TEMPORAIS

74

A concessionária de uma rodovia precisa estimar a quantidade mensal de **veículos** que trafegarão em determinado trecho no ano seguinte, com base em um histórico de 12 anos (jun/11 a mai/23).



Volume de tráfego de veículos



Aplicando o modelo na base de dados, podemos construir um **gráfico comparativo** dos valores reais observados *versus* valores preditos pelo modelo (ao lado).

Neste *case*, **REQM = 24.664**.

Ou seja, os valores preditos pelo modelo desviam-se dos valores reais em cerca de **24.664 veículos**, em média.

Arquivo: Veiculos (.txt)

@LABDATA FIA. Copyright all rights reserved.



Case: Tráfego de Veículos


5. MODELOS PARA SÉRIES NÃO ESTACIONÁRIAS | SÉRIES TEMPORAIS

75

A concessionária de uma rodovia precisa estimar a quantidade mensal de **veículos** que trafegarão em determinado trecho no ano seguinte, com base em um histórico de 12 anos (jun/11 a mai/23).



Volume de tráfego de veículos



Projetando a fórmula do modelo estimado para os próximos 12 meses, obtemos as seguintes **previsões** (destacadas em **vermelho** no gráfico ao lado):

- | | |
|-----------------------------------|-----------------------------------|
| ✓ jun/23: 448.165 veículos | ✓ dez/23: 649.553 veículos |
| ✓ jul/23: 446.676 veículos | ✓ jan/24: 634.999 veículos |
| ✓ ago/23: 458.870 veículos | ✓ fev/24: 540.303 veículos |
| ✓ set/23: 502.402 veículos | ✓ mar/24: 494.211 veículos |
| ✓ out/23: 496.468 veículos | ✓ abr/24: 435.552 veículos |
| ✓ nov/23: 572.177 veículos | ✓ mai/24: 479.388 veículos |

Ou seja, estimamos que os padrões de tendência e sazonalidade se manterão nos próximos 12 meses.

Arquivo: Veiculos (.txt)

@LABDATA FIA. Copyright all rights reserved.



Case: Inadimplência

5. MODELOS PARA SÉRIES NÃO ESTACIONÁRIAS | SÉRIES TEMPORAIS

76

Um banco deseja prever o % de clientes **inadimplentes** no cartão de crédito (ou seja, que atrasam o pagamento de sua fatura) para os 12 meses seguintes, com base em um histórico de 5 anos.



- a) Analise o gráfico da série. Ela parece estacionária, ou possui tendências/sazonalidade?
- b) Realize o teste de Dickey-Fuller generalizado e afirme formalmente se a série é estacionária ou não.
- c) Ajuste o melhor modelo (S)ARIMA para a série. Qual foi o modelo identificado? Escreva a sua equação.
- d) Construa um gráfico único comparando a evolução da série com os valores preditos pelo modelo. Analisando visualmente, o modelo parece adequado?
- e) Avalie a qualidade do modelo a partir do índice REQM.
- f) Projete o percentual de clientes inadimplentes para os próximos 12 meses.

Arquivo: Carteira_Clientes (.txt)

@LABDATA FIA. Copyright all rights reserved.



lab.data



6. Modelo com Variáveis Exógenas



Como Predizer a Série por Meio de Outras Variáveis?

6. MODELO COM VARIÁVEIS EXÓGENAS | SÉRIES TEMPORAIS

78

- Note que, nos modelos das classes (S)ARIMA, uma variável era projetada apenas a partir de dados históricos dela mesma. Porém, é comum que se tenha interesse em modelar uma série temporal a partir de dados de **outras variáveis explicativas**. Estas são chamadas, geralmente, de variáveis **exógenas**, ou **externas**.
- Uma das alternativas para isso é o modelo de **regressão linear temporal**. Diferentemente da regressão linear tradicional, na qual as observações e erros eram **independentes**, agora, temos que considerar que as observações possuem um grau potencial de **dependência** entre si.



Modelo de Regressão Linear Temporal

6. MODELO COM VARIÁVEIS EXÓGENAS | SÉRIES TEMPORAIS

79

O modelo de **regressão linear temporal** para uma resposta quantitativa indexada pelo tempo Y_t , a partir de k variáveis explicativas também indexadas pelo tempo $X_{1,t}, \dots, X_{k,t}$, pode ser escrito como:

$$Y_t = \beta_0 + \beta_1 X_{1,t} + \dots + \beta_k X_{k,t} + \eta_t$$

A diferença é que, agora, os resíduos η_t **não são independentes**, e sim, seguem um processo **ARIMA** (p, d, q) . Ou seja:

$$(1 - B)^d \eta_t = \phi_1 (1 - B)^d \eta_{t-1} + \dots + \phi_p (1 - B)^d \eta_{t-p} + \epsilon_t + \theta_1 \epsilon_{t-1} + \dots + \theta_q \epsilon_{t-q}$$

Exemplos:

- Modelo com 1 explicativa e erros ARIMA (1,0,1): $Y_t = \beta_0 + \beta_1 X_{1,t} + \eta_t$, onde $\eta_t = \phi_1 \eta_{t-1} + \epsilon_t + \theta_1 \epsilon_{t-1}$
- Modelo com 2 explicativas e erros ARIMA (1,1,0): $Y_t = \beta_0 + \beta_1 X_{1,t} + \beta_2 X_{2,t} + \eta_t$, onde $(1 - B)\eta_t = \phi_1 (1 - B)\eta_{t-1} + \epsilon_t$

Caso haja comportamento sazonal, pode-se generalizar os resíduos para um processo **SARIMA** $(p, d, q) \times (P, D, Q)^m$.

* Letra grega β : lê-se como 'béta'

* Letra grega θ : lê-se como 'téta'

* Letra grega η : lê-se como 'êta'

* Letra grega ϵ : lê-se como 'épsilon'

* Letra grega ϕ : lê-se como 'fi'




Case: Inflação

6. MODELO COM VARIÁVEIS EXÓGENAS | SÉRIES TEMPORAIS

80

Uma consultoria financeira deseja projetar o valor do Índice de Preços ao Consumidor Amplo (IPCA), principal índice para cálculo da inflação oficial do país, em função do Índice Geral de Preços de Mercado (IGP-M), também utilizado como indexador de inflação, especialmente nos setores imobiliário e energético. Vamos utilizar dados históricos das variações mensais (em %) dos índices IPCA e IGP-M ao longo de 36 meses (jan/21 a dez/23), a fim de projetar o mês seguinte (jan/24).



Arquivo: Inflacao (.txt)

@LABDATA FIA. Copyright all rights reserved.



Case: Inflação

6. MODELO COM VARIÁVEIS EXÓGENAS | SÉRIES TEMPORAIS

81

Uma consultoria financeira deseja projetar o valor do Índice de Preços ao Consumidor Amplo (IPCA), principal índice para cálculo da inflação oficial do país, em função do Índice Geral de Preços de Mercado (IGP-M), também utilizado como indexador de inflação, especialmente nos setores imobiliário e energético. Vamos utilizar dados históricos das variações mensais (em %) dos índices IPCA e IGP-M ao longo de 36 meses (jan/21 a dez/23), a fim de projetar o mês seguinte (jan/24).



```
call:  
lm(formula = serie_ipca ~ serie_igpm)
```

Modelo de regressão linear simples

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	0.0047093	0.0007738	6.086	0.000000666	***
serie_igpm	0.1524677	0.0559545	2.725	0.0101	*

signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.004299 on 34 degrees of freedom
Multiple R-squared: 0.1792, Adjusted R-squared: 0.1551

Arquivo: Inflacao (.txt)



Case: Inflação

6. MODELO COM VARIÁVEIS EXÓGENAS | SÉRIES TEMPORAIS

82

Uma consultoria financeira deseja projetar o valor do Índice de Preços ao Consumidor Amplo (IPCA), principal índice para cálculo da inflação oficial do país, em função do Índice Geral de Preços de Mercado (IGP-M), também utilizado como indexador de inflação, especialmente nos setores imobiliário e energético. Vamos utilizar dados históricos das variações mensais (em %) dos índices IPCA e IGP-M ao longo de 36 meses (jan/21 a dez/23), a fim de projetar o mês seguinte (jan/24).



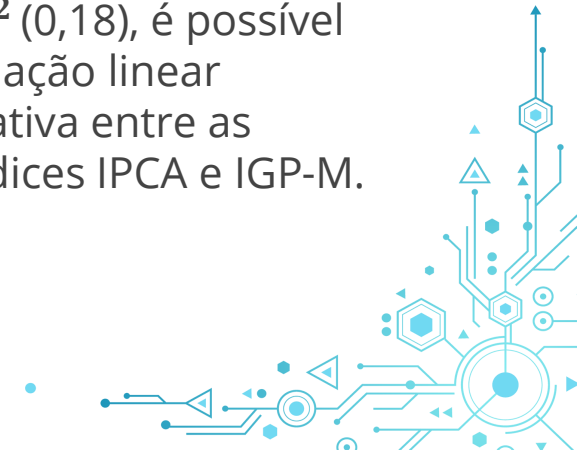
```
call:
lm(formula = serie_ipca ~ serie_igpm)

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  0.0047093  0.0007738   6.086 0.000000666 ***
serie_igpm    0.1524677  0.0559545   2.725  0.0101 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.004299 on 34 degrees of freedom
Multiple R-squared:  0.1792    Adjusted R-squared:  0.1551
```

- Ajustando um modelo de **regressão linear simples** para avaliar a associação entre a variação de IPCA e a variação de IGP-M, vemos que os parâmetros β_0 e β_1 são estatisticamente **diferentes de zero**, com alta confiança.
- Logo, apesar do **baixo R^2** (0,18), é possível afirmar que existe associação linear estatisticamente significativa entre as variações mensal nos índices IPCA e IGP-M.

Arquivo: Inflacao (.txt)



Case: Inflação

6. MODELO COM VARIÁVEIS EXÓGENAS | SÉRIES TEMPORAIS

83

Uma consultoria financeira deseja projetar o valor do Índice de Preços ao Consumidor Amplo (IPCA), principal índice para cálculo da inflação oficial do país, em função do Índice Geral de Preços de Mercado (IGP-M), também utilizado como indexador de inflação, especialmente nos setores imobiliário e energético. Vamos utilizar dados históricos das variações mensais (em %) dos índices IPCA e IGP-M ao longo de 36 meses (jan/21 a dez/23), a fim de projetar o mês seguinte (jan/24).



```
call:
lm(formula = serie_ipca ~ serie_igpm)

Coefficients:
              Estimate Std. Error t value    Pr(>|t|)
(Intercept)  0.0047093   0.0007738   6.086 0.000000666 ***
serie_igpm    0.1524677   0.0559545   2.725    0.0101    *
---
signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.004299 on 34 degrees of freedom
Multiple R-squared:  0.1792    Adjusted R-squared:  0.1551
```

- Entretanto, ao ajustar este modelo, estamos **ignorando** a estrutura de **correlação temporal** existente entre as observações.

Arquivo: Inflacao (.txt)



Case: Inflação

6. MODELO COM VARIÁVEIS EXÓGENAS | SÉRIES TEMPORAIS

84

Uma consultoria financeira deseja projetar o valor do Índice de Preços ao Consumidor Amplo (IPCA), principal índice para cálculo da inflação oficial do país, em função do Índice Geral de Preços de Mercado (IGP-M), também utilizado como indexador de inflação, especialmente nos setores imobiliário e energético. Vamos utilizar dados históricos das variações mensais (em %) dos índices IPCA e IGP-M ao longo de 36 meses (jan/21 a dez/23), a fim de projetar o mês seguinte (jan/24).



```
Series: serie_ipca  
Regression with ARIMA(1,0,0) errors
```

Modelo de regressão temporal

Coefficients:

	ar1	intercept	xreg
	0.5507	0.0046	0.1347
s.e.	0.1393	0.0013	0.0623

```
sigma^2 = 0.0000133: log likelihood = 152.41  
AIC=-296.81 AICc=-295.52 BIC=-290.48
```

Arquivo: Inflacao (.txt)

@LABDATA FIA. Copyright all rights reserved.



lab.data



Case: Inflação

6. MODELO COM VARIÁVEIS EXÓGENAS | SÉRIES TEMPORAIS

85

Uma consultoria financeira deseja projetar o valor do Índice de Preços ao Consumidor Amplo (IPCA), principal índice para cálculo da inflação oficial do país, em função do Índice Geral de Preços de Mercado (IGP-M), também utilizado como indexador de inflação, especialmente nos setores imobiliário e energético. Vamos utilizar dados históricos das variações mensais (em %) dos índices IPCA e IGP-M ao longo de 36 meses (jan/21 a dez/23), a fim de projetar o mês seguinte (jan/24).



```
Series: serie_ipca  
Regression with ARIMA(1,0,0) errors
```

Coefficients:

	ar1	intercept	xreg
	0.5507	0.0046	0.1347
s.e.	0.1393	0.0013	0.0623

```
sigma^2 = 0.0000133: log likelihood = 152.41  
AIC=-296.81 AICc=-295.52 BIC=-290.48
```

- Agora, ajustamos uma **regressão linear temporal** com a função *auto.arima* do R.
- O termo **xreg** corresponde à variável explicativa (IGP-M).
- Os resíduos do modelo de regressão linear seguem um modelo temporal **AR(1)**.

Arquivo: Inflacao (.txt)

@LABDATA FIA. Copyright all rights reserved.



Case: Inflação

6. MODELO COM VARIÁVEIS EXÓGENAS | SÉRIES TEMPORAIS

86

Uma consultoria financeira deseja projetar o valor do Índice de Preços ao Consumidor Amplo (IPCA), principal índice para cálculo da inflação oficial do país, em função do Índice Geral de Preços de Mercado (IGP-M), também utilizado como indexador de inflação, especialmente nos setores imobiliário e energético. Vamos utilizar dados históricos das variações mensais (em %) dos índices IPCA e IGP-M ao longo de 36 meses (jan/21 a dez/23), a fim de projetar o mês seguinte (jan/24).



```
Series: serie_ipca  
Regression with ARIMA(1,0,0) errors
```

Coefficients:

	ar1	intercept	xreg
	0.5507	0.0046	0.1347
s.e.	0.1393	0.0013	0.0623

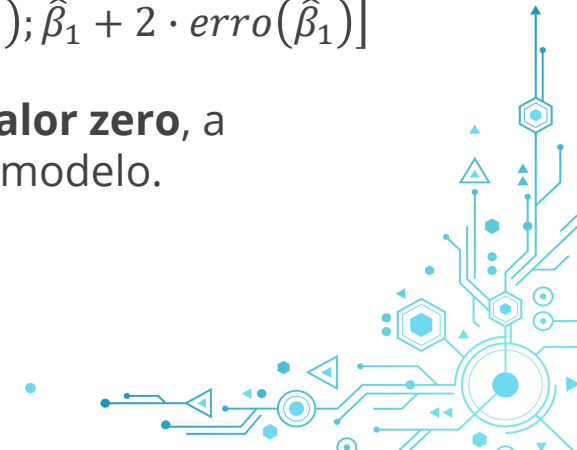
```
sigma^2 = 0.0000133: log likelihood = 152.41  
AIC=-296.81 AICc=-295.52 BIC=-290.48
```

- **Observação:** A função *auto.arima* não fornece o p -valor do teste de nulidade do parâmetro β_1 , associado à variável explicativa (*xreg*). Para avaliar se ela é significativa no modelo, temos que calcular o intervalo de confiança de 95%:

$$IC(\beta_1; 95\%) = [\hat{\beta}_1 - 2 \cdot \text{erro}(\hat{\beta}_1); \hat{\beta}_1 + 2 \cdot \text{erro}(\hat{\beta}_1)]$$

Se o intervalo **não incluir o valor zero**, a variável deve permanecer no modelo.

Arquivo: Inflacao (.txt)



Case: Inflação

6. MODELO COM VARIÁVEIS EXÓGENAS | SÉRIES TEMPORAIS

87

Uma consultoria financeira deseja projetar o valor do Índice de Preços ao Consumidor Amplo (IPCA), principal índice para cálculo da inflação oficial do país, em função do Índice Geral de Preços de Mercado (IGP-M), também utilizado como indexador de inflação, especialmente nos setores imobiliário e energético. Vamos utilizar dados históricos das variações mensais (em %) dos índices IPCA e IGP-M ao longo de 36 meses (jan/21 a dez/23), a fim de projetar o mês seguinte (jan/24).



```
Series: serie_ipca  
Regression with ARIMA(1,0,0) errors
```

Coefficients:

	ar1	intercept	xreg
	0.5507	0.0046	0.1347
s.e.	0.1393	0.0013	0.0623

```
sigma^2 = 0.0000133: log likelihood = 152.41  
AIC=-296.81 AICc=-295.52 BIC=-290.48
```

Arquivo: Inflacao (.txt)


@LABDATA FIA. Copyright all rights reserved.



lab.data

$$IC(\beta_1; 95\%) = [\hat{\beta}_1 - 2 \cdot \text{erro}(\hat{\beta}_1); \hat{\beta}_1 + 2 \cdot \text{erro}(\hat{\beta}_1)]$$
$$IC(\beta_1; 95\%) = [0,1347 - 2 \cdot 0,0623; 0,1347 + 2 \cdot 0,0623]$$
$$= [0,0101; 0,2593]$$

- A amostra nos fornece 95% de confiança de que o parâmetro populacional β_1 está entre **0,0101** e **0,2593**. Logo, assumimos que ele é diferente de zero, e que a variação mensal no IPCA está linearmente associada à variação mensal no IGP-M.




Case: Inflação

6. MODELO COM VARIÁVEIS EXÓGENAS | SÉRIES TEMPORAIS

88

Comparação dos modelos para a variação mensal no IPCA



Arquivo: Inflacao (.txt)

@LABDATA FIA. Copyright all rights reserved.



Case: Inflação

6. MODELO COM VARIÁVEIS EXÓGENAS | SÉRIES TEMPORAIS

89

Uma consultoria financeira deseja projetar o valor do Índice de Preços ao Consumidor Amplo (IPCA), principal índice para cálculo da inflação oficial do país, em função do Índice Geral de Preços de Mercado (IGP-M), também utilizado como indexador de inflação, especialmente nos setores imobiliário e energético. Vamos utilizar dados históricos das variações mensais (em %) dos índices IPCA e IGP-M ao longo de 36 meses (jan/21 a dez/23), a fim de projetar o mês seguinte (jan/24).



O **REQM** da regressão linear foi reduzido em cerca de **17%** (de 0,42pp para 0,35pp) a partir da incorporação de erros correlacionados, segundo o modelo AR(1).

Logo, o modelo de **regressão linear temporal** é mais adequado do que a **regressão linear simples** para este *case*, conforme esperado.

Arquivo: Inflacao (.txt)

@LABDATA FIA. Copyright all rights reserved.



lab.data



Case: Inflação

6. MODELO COM VARIÁVEIS EXÓGENAS | SÉRIES TEMPORAIS

90

Uma consultoria financeira deseja projetar o valor do Índice de Preços ao Consumidor Amplo (IPCA), principal índice para cálculo da inflação oficial do país, em função do Índice Geral de Preços de Mercado (IGP-M), também utilizado como indexador de inflação, especialmente nos setores imobiliário e energético. Vamos utilizar dados históricos das variações mensais (em %) dos índices IPCA e IGP-M ao longo de 36 meses (jan/21 a dez/23), a fim de projetar o mês seguinte (jan/24).



Para **previsão** da série da variável resposta (variação de IPCA) para o mês de jan/24, é necessário estipular um valor para a série da variável explicativa (variação de IGP-M) neste mesmo mês.

- O valor médio das variações mensais de IGP-M nos últimos 6 meses de histórico (de jul/23 a dez/23) foi de 0,0022 ,ou seja, 0,22%. Assumindo esse valor como uma estimativa para a variação de IGP-M no mês de jan/24, a previsão de variação no IPCA neste mês é de **0,49%**.

Arquivo: Inflacao (.txt)


@LABDATA FIA. Copyright all rights reserved.



Case: Inflação

6. MODELO COM VARIÁVEIS EXÓGENAS | SÉRIES TEMPORAIS

91



Previsão
para jan/24:
0,0049

Arquivo: Inflacao (.txt)

@LABDATA FIA. Copyright all rights reserved.



Case: Inflação

6. MODELO COM VARIÁVEIS EXÓGENAS | SÉRIES TEMPORAIS

92

Uma consultoria financeira deseja projetar o valor do Índice de Preços ao Consumidor Amplo (IPCA), principal índice para cálculo da inflação oficial do país, em função do Índice Geral de Preços de Mercado (IGP-M), também utilizado como indexador de inflação, especialmente nos setores imobiliário e energético. Vamos utilizar dados históricos das variações mensais (em %) dos índices IPCA e IGP-M ao longo de 36 meses (jan/21 a dez/23), a fim de projetar o mês seguinte (jan/24).



Para **previsão** da série da variável resposta (variação de IPCA) para o mês de jan/24, é necessário estipular um valor para a série da variável explicativa (variação de IGP-M) neste mesmo mês.

- O valor histórico real de variação do IGP-M em jan/24 foi de 0,07%. Caso esse valor fosse conhecido a priori e utilizado no modelo, a estimativa de variação do **IPCA** neste mês diminuiria de 0,49% para **0,47%**.
- O valor histórico real de variação do IPCA em jan/24 foi de **0,42%**, um pouco abaixo da estimativa.

Arquivo: Inflacao (.txt)

@LABDATA FIA. Copyright all rights reserved.



Case: Energia Renovável

6. MODELO COM VARIÁVEIS EXÓGENAS | SÉRIES TEMPORAIS

93

A prefeitura de um município está viabilizando gradativamente para os habitantes a **distribuição de energia** a partir de fontes **renováveis**. Temos uma base com dados quinzenais de um período de 2 anos para as seguintes variáveis:


- **Capacidade instalada** para geração de energia renovável, em MW (*megawatt*)
- **Consumo quinzenal** de energia elétrica renovável, em GWh (*gigawatt/hora*)

Deseja-se avaliar se o consumo de energia renovável está relacionado linearmente com a capacidade instalada, bem como prever o consumo para o mês seguinte, supondo que a capacidade instalada seja de 200MW na quinzena seguinte, e 230MW na quinzena subsequente.



- Analise o gráfico de evolução das séries de capacidade instalada e de consumo quinzenal. Elas parecem estacionárias, ou possuem tendências/sazonalidade?
- Analise o gráfico de dispersão entre as duas séries. Parece existir correlação linear entre capacidade instalada e consumo?
- Realize o teste de Dickey-Fuller generalizado e afirme formalmente se as séries são estacionárias ou não.
- Ajuste o melhor modelo ARIMA para o consumo quinzenal, sem considerar a capacidade instalada. Qual foi o modelo identificado? Escreva a sua equação.

Arquivo: Energia (.txt)



Case: Energia Renovável

6. MODELO COM VARIÁVEIS EXÓGENAS | SÉRIES TEMPORAIS

94

A prefeitura de um município está viabilizando gradativamente para os habitantes a **distribuição de energia** a partir de fontes **renováveis**. Temos uma base com dados quinzenais de um período de 2 anos para as seguintes variáveis:

- **Capacidade instalada** para geração de energia renovável, em MW (*megawatt*)
- **Consumo quinzenal** de energia elétrica renovável, em GWh (*gigawatt/hora*)

Deseja-se avaliar se o consumo de energia renovável está relacionado linearmente com a capacidade instalada, bem como prever o consumo para o mês seguinte, supondo que a capacidade instalada seja de 200MW na quinzena seguinte, e 230MW na quinzena subsequente.



- Ajuste um modelo de regressão linear simples para o consumo quinzenal, utilizando a capacidade instalada como variável explicativa. Existe associação estatisticamente significativa entre as variáveis, com 95% de confiança? Obs.: mantenha o intercepto no modelo, mesmo que não seja significativo.
- Ajuste um modelo de regressão linear temporal para o consumo quinzenal, utilizando a capacidade instalada e erros (S)ARIMA. Qual foi o melhor modelo identificado para os erros? Escreva a sua equação.
- No modelo do item (f), a presença da variável de capacidade instalada foi significativa? Justifique por meio do cálculo do intervalo de confiança associado ao coeficiente que multiplica esta variável.

Arquivo: Energia (.txt)



Case: Energia Renovável

6. MODELO COM VARIÁVEIS EXÓGENAS | SÉRIES TEMPORAIS

95

A prefeitura de um município está viabilizando gradativamente para os habitantes a **distribuição de energia** a partir de fontes **renováveis**. Temos uma base com dados quinzenais de um período de 2 anos para as seguintes variáveis:

- **Capacidade instalada** para geração de energia renovável, em MW (*megawatt*)
- **Consumo quinzenal** de energia elétrica renovável, em GWh (*gigawatt/hora*)

Deseja-se avaliar se o consumo de energia renovável está relacionado linearmente com a capacidade instalada, bem como prever o consumo para o mês seguinte, supondo que a capacidade instalada seja de 200MW na quinzena seguinte, e 230MW na quinzena subsequente.



- h) Construa um gráfico único comparando a evolução da série de consumo quinzenal com os valores preditos dos três modelos construídos nos itens anteriores. Analisando visualmente, qual dos três modelos parece se ajustar melhor aos dados ao longo do tempo?
- i) Justifique qual é, de fato, o modelo que melhor se adequa aos dados, a partir dos índices REQM.
- j) Utilizando o melhor modelo identificado no item (i), projete o consumo de energia renovável para as próximas 2 quinzenas, utilizando as informações do enunciado. Faça um gráfico da evolução quinzenal do consumo, incluindo dois novos pontos referentes às projeções.

Arquivo: Energia (.txt)



- Morettin, P. A., Toloi, C. M. C. *Análise de Séries Temporais*. 2ª edição. Blucher, 2006.
- Hyndman, R. J., Athanasopoulos, G. *Forecasting: Principles and Practice*. 3ª edição. Otexts, 2021.
- Shumway, R. H., Stoffer, D. S. *Time Series Analysis and Its Applications*. Springer, 2006.





lab.data

<http://labdata.fia.com.br>
Instagram: @labdatafia
Facebook: @LabdataFIA

